

문서와 논문을 요약하는 AI 연구원

문서와 논문을 요약하는 AI 연구원

1. PDF 문서 전처리하기
2. 논문을 요약하는 AI 연구원 완성하기

1. PDF 문서 전처리하기

- PDF 파일로 저장되어 있는 문서를 GPT와 같은 언어 모델을 이용해 작업하려면 문서를 전처리 하는 과정이 필요
- PyMuPDF 패키지를 사용해 PDF 파일에서 텍스트를 추출할 수 있음
 - PyMuPDF 가이드 문서 웹 페이지: <https://pypi.org/project/PyMuPDF/>
- 텍스트로 변환할 때 페이지 번호나 header, footer 등의 정보가 섞일 수 있음
- 이러한 요소들을 처리하는 PDF 파일 텍스트 전처리 과정을 다뤄 봄

1. PDF 문서 전처리하기

- (실습) PDF 파일을 텍스트 파일로 변환하기

1. 가상 환경 설정

```
# 가상 환경 생성
$ python -m venv .venv

# 윈도우 가상 환경 활성화
$ .venv/Scripts/activate # 맥 환경에서는 Scripts를 bin으로 변경
(.venv)
$ python -m pip install --upgrade pip
```

2. chap03에서 .env 파일과 requirements.txt 파일 복사해서 프로젝트 폴더에 붙여넣기. 그리고 다음 명령 실행

```
# chap03에 설치했던 패키지 설치
(.venv)
$ pip install -r requirements.txt
```

3. 터미널 창에 pip install PyMuPDF를 입력하여 추가 패키지 설치

```
(.venv)
$ pip install PyMuPDF
```

1. PDF 문서 전처리하기

● (실습) PDF 파일을 텍스트 파일로 변환하기

4. 요약할 PDF 파일 준비

- 텍스트 영역 선택 가능 파일이어야 함
- <https://ksae.re.kr>
- 논문 제목: 과정기반 작물모형을 이용한 웹 기반 밀 재배관리 의사결정 지원시스템 설계 및 구축

1. 서론

우리나라 밀 소비량은 지속적으로 증가하고 있지만 자급률은 1% 수준밖에 되지 않아 안정적인 생산기반을 마련할 필요가 제기되고 있다. 쌀과 밀, 서류, 콩 등을 포함한 우리나라 1인당 양곡소비량은 2022년 기준 총 125.4 kg이며, 이 중에서 쌀이 약 45.2% (56.7 kg), 그다음으로 밀이 30.3% (38.0 kg)를 차지한다. 2022년 1인당 밀 소비량을 기준으로 밀 소비량은 2012년 (32.9 kg/인)에 비해 연간 0.5%씩 증가하고 있다 (MAFRA, 2023a). 반면 식량자급률 (사료용 제외)은 2022년 기준 1.3%를 밑도는 수준이다 (MAFRA, 2023b). 이러한 문제

The screenshot shows the homepage of the Korean Society of Agricultural Engineers (KSAE) website. The browser address bar displays 'ksae.re.kr/html/sub04-01.asp'. The website header includes the KSAE logo and navigation links: '학회소개', '각종위원회', '회원공간', '간행물', '학술발표회', and '학회공지'. A large banner image with the text '간행물' is visible. Below the banner, there is a sidebar with a green '간행물' button and a white '학술지' button. The main content area features a search bar with the text 'KISS' and a search button. The search results show a document titled '과정기반 작물모형을 이용한 웹 기반 밀 재배관리 의사결정 지원시스템 설계 및 구축' (Design and Construction of a Decision Support System for Web-based Rice Cultivation Management Using Process-based Crop Model). The document is listed as '1' and includes the authors '김솔희 (Kim Solhee), 석승원 (Seok Seungwon), 청리광 (Cheng Liguang), 장태일 (Jang Taeil), 김태곤 (Kim Taegon)' and the year '2024'. The document is from the '한국농공학회논문집' (KSAE Journal) and is 66(4) pages long, 17-26 (10p) in length. A '다운로드' (Download) button is present next to the document entry.

1. PDF 문서 전처리하기

- (실습) PDF 파일을 텍스트 파일로 변환하기

5. 내려 받은 PDF 파일을 사용하기 위해 chap04/data 폴더 만들어 파일 담기
6. chap04/sec01/ 폴더에 pdf_to_text.py 파일을 만들고 PDF에서 텍스트를 잘 읽어 오는지 코드 작성

```
import pymupdf
import os

pdf_file_path = "data/과정기반 작물모형을 ....pdf"
doc = pymupdf.open(pdf_file_path)

full_text = ''



for page in doc: # 문서 페이지 반복
    text = page.get_text() # 페이지 텍스트 추출
    full_text += text

... ( 생략 ) ...
```

1. PDF 문서 전처리하기

- (실습) PDF 파일을 텍스트 파일로 변환하기

7. chap04 폴더 안에 파일을 저장할 output 폴더를 만들어 코드 실행 후 저장된 파일 열어 확인



- 중간에 페이지 번호와 학회지 이름, 논문 제목이 같이 끼어 있음

1. PDF 문서 전처리하기

● (실습) PDF 파일 전처리 하기

과정기반 작물모형을 이용한 힘 기반 및 저배관리 의사결정 지원시스템 설계 및 구축	헤더
터 기반의 노지 스마트농업 시범사업을 2020년부터 운영하고 있다. 한 예로, 경북 안동 사과 주산지인 경북 사과 주산지를 대상으로 관수·관비 등 ICT 기반 스마트 농기계 (드론, 무인트랙터 등)를 지원하고, 기존 농산물산지유통시설 (Agricultural Product Processing Complex, APC) 스마트화를 통해 산지에서 발생하는 환경·생육·경영 데이터를 수집하여 수급 예측을 모색하고 있다 (KIFA, 2024). 노지작물의 디지털 기술을 활용한 스마트 농업은 재배 시기별로 환경과 작물 성장 상황을 고려하여 적절한 비료 공급, 관개, 수확시기 조절 등 최적의 계획을 통한 생산성 향상을 도모한다. 이를 위해 작물모형을 활용한 의사결정 지원시스템 (Decision Support System, 이하 DSS)을 제안하는 바, 재배 환경과 관리 방법에 따른 작물의 생육 예측 결과를 제공함으로써 작물관리에 대한 농가의 의사결정에 도움을 줄 수 있다. 특히 노동력 및 농자재를 최소화하여 투입하면서 생산량과 품질을 극대화할 수 있도록 작기 내에 다양한 열량인자를 시계열로 고려할 필요가 있다. 이때 필요한 모형이 과정기반 작	본문 내용
고 있다. 하지만 데이터의 양과 질에 민감하여 충분한 데이터셋이 확보된 작물에만 적용할 수 있고, 블랙박스 모형이기 때문에 잘 보정된 모델이라 할지라도 생산성에 영향을 미치는 원인 인자를 규명하기 어려운 단점을 갖고 있다 (Chang et al., 2023). 농업부문의 의사결정지원시스템은 농가의 작물 계획, 생산과 유통, 소비 전 과정에서 데이터를 기반으로 작물 추천 및 생산성 향상, 안정적 소득 증대 등 다양한 목적으로 개발되고 있다. 재배 전 단계의 의사결정은 영농 계획과 자식이 상대적으로 적은 농업인과 귀농인을 대상으로 재배 목적지, 재배 형태, 작목 등을 선택할 때 농업기상 환경을 고려하여 초기 농업 경영을 위한 의사결정에 도움을 줄 수 있는 지원도구들을 제시할 수 있는 시스템이 개발되고 있다. Kim and Cho (2022)는	다양한 영농 DSS 가운데 현재 개발되고 있는 재배관리 DSS는 대부분 시설원예를 대상으로 하고 있다. 시설원예 분야 DSS는 최적환경을 설정하고, 이에 맞춰 생육환경을 운영하기 때문에, 효율성을 높이기 위한 최적화 기능이 주된 목적이다. 투입자원 및 에너지를 최소화하면서 목표한 환경을 조성하는 복합환경제어가 대표적인 시스템이다. 반면 노지작물은 환경을 인위적으로 조절하기 어렵기 때문에, 생산성을 높이기 위한 미세조절보다는 생육장애를 일으킬 수 있는 환경을 회피하여 생산성의 급격한 저하를 막는 방향으로 재배기술이 운용된다. 따라서 노지작물을 재배하는 과정에서 실시간으로 기상 및 토양환경 변화를 고려하여 현 상태에서의 생산량 예상과 더불어 다년간의 시계열 환경 데이터로 앞으로 일어날 수 있는 생육장애 상황을 고려할 필요가 있으나, 현재
18 · Journal of the Korean Society of Agricultural Engineers, 66(4), 2024, 7	푸터

1. PDF 문서 전처리하기

- (실습) PDF 파일 전처리 하기

1. PDF 파일에서 header와 footer를 제외하고 텍스트를 추출하는 코드(pdf_to_text_without_header_footer.py)

```
import pymupdf
import os

pdf_file_path = "data/과정기반 작물모형을 ...pdf"
doc = pymupdf.open(pdf_file_path)

header_height = 80
footer_height = 80

full_text = ''

for page in doc:
    rect = page.rect # 페이지 크기 가져오기

    header = page.get_text(clip=(0, 0, rect.width , header_height))
    footer = page.get_text(clip=(0, rect.height - footer_height, rect.width , rect.height))
    text = page.get_text(clip=(0, header_height, rect.width , rect.height - footer_height))



    full_text += text + '\n-----\n'

... ( 생략 ) ...
```

1. PDF 문서 전처리하기

- (실습) PDF 파일 전처리 하기

2. 코드 실행 후 output 폴더에 저장된 결과



2. 논문을 요약해 주는 AI 연구원 완성하기

- (실습) 텍스트 요약 프롬프트 만들기

1. chap04/sec02/ 폴더에 summary.py 파일을 새로 만들고 텍스트 파일을 요약하는 코드 작성

```
from openai import OpenAI
from dotenv import load_dotenv
import os

load_dotenv()
api_key = os.getenv('OPENAI_API_KEY')

def summarize_txt(file_path: str): # ①
    client = OpenAI(api_key=api_key)

    # 주어진 텍스트 파일을 읽어들인다.
    with open(file_path, 'r', encoding='utf-8') as f:
        txt = f.read()


    # 요약을 위한 시스템 프롬프트를 생성한다.
    system_prompt = f'''
너는 다음 글을 요약하는 봇이다. 아래 글을 읽고, 저자의 문제 인식과 주장을 파악하고, 주요 내용을 요약하라.

... ( 생략 ) ...
```

2. 논문을 요약해 주는 AI 연구원 완성하기

● (실습) 텍스트 요약 프롬프트 만들기

2. 코드 실행 후 output 폴더에 생성된 파일 열기



```
crop_model_summary.txt
파일 편집 보기 H1 H2 H3 B I S E田 A
# 제목
과정기반 작물모형을 이용한 웹 기반 밀 재배관리 의사결정지원시스템 설계 및 구축
## 저자의 문제 인식 및 주장 (15문장 이내)
- 우리나라 밀 자급률은 약 1%대에 머물러 안정적인 생산기반 확립이 시급하다.
- 밀 재배의 대부분이 노지에서 이뤄지며 기상변화의 영향이 크고 외부 요인에 의한 생산량 변동이 심하다.
- 농가의 노동력 절감과 생산성 향상을 위해 노지작물도 디지털 기반 의사결정 지원이 필요하다.
- 현행 의사결정지원시스템은 주로 시설원예에 초점을 맞추고 있어 노지재배를 위한 시스템은 부족하다.
- 생육단계별 환경요인과 관리방법을 연계해 다년간의 시계열 데이터를 활용하는 의사결정 도구가 필요하다.
- 과정기반 작물모형은 생리기작과 환경 요인을 반영하므로 노지재배의 상황별 예측에 적합하다.
- APSIM은 모듈형 오픈소스 프레임워크로, 국내 상황에 맞춘 모듈 개발이 가능하다.
- 본 연구는 APSIM을 웹 기반으로 구현해 현재 상태의 생산량 추정과 미래 시나리오를 통한 잠재생산량 예측을 제시한다.
- 매일 기상 데이터를 수집하고, 과거 40년 데이터를 활용한 시나리오로 미래를 분석한다.
- 대시보드형 웹서비스로 농가가 손쉽게 접근하고 의사결정을 지원하도록 설계되었다.
- 가뭄·홍수 등 10년 주기의 자연재난 상황에서도 피해 규모를 예측해 선제조치를 가능하게 한다.
- 시스템은 전국의 기상데이터와 토양정보를 바탕으로 작물모형을 구동하므로 타 지역으로의 확장성이 크다.
- 밀 품종 새금강밀에 대한 재배실험 데이터를 이용해 모형 파라미터를 보정하고 검증하였다.
- 현재 상태의 기상조건과 과거 데이터를 바탕으로 현재 생산량을 추정하고, 과거 40년 데이터를 이용한 미래 시나리오로 잠재생산량을 제시한다.
- 향후 질소 함량 등 추가 인자를 포함한 모델 고도화로 재배관리 의사결정의 정확성과 품질 향상에 기여할 수 있다.
## 저자 소개
- Solhee Kim — Assistant Research Professor, Department of Smart Farm, Jeonbuk National University.
- Seungwon Seok — Undergraduate, Department of Smart Farm, Jeonbuk National University.
- Liguang Cheng — Ph.D. Student, Department of Rural Construction Engineering, Jeonbuk National University.
- Taeil Jang — Professor, Department of Rural Construction Engineering, Institute of Agricultural Science & Technology, Jeonbuk National University.
- Taegon Kim — Assistant Professor, Department of Smart Farm, Jeonbuk National University; corresponding author (taegon@jbnu.ac.kr).
줄 29, 열 133 | 1,539자 일반 텍스트 100% Windows (CRLF) UTF-8
```

2. 논문을 요약해 주는 AI 연구원 완성하기

- (실습) PDF 내용 요약하여 출력하기

1. 최종적으로 PDF 파일만 입력하면 요약 결과를 저장하는 AI 연구원 완성

- summary.py 파일에, 앞에서 만든 PDF 파일을 텍스트로 변환해 저장하는 pdf_without_header_footer.py 코드를 pdf_to_text() 함수로 만들어 추가

```
from openai import OpenAI
from dotenv import load_dotenv
import os
import pymupdf

load_dotenv()
api_key = os.getenv('OPENAI_API_KEY')

def pdf_to_text(pdf_file_path: str): # pdf_without_header_footer.py 파일 내용 그대로 가져옴
    doc = pymupdf.open(pdf_file_path)

    header_height = 80
    footer_height = 80

    full_text = ''


... ( 생략 ) ...
```

2. 논문을 요약해 주는 AI 연구원 완성하기

● (실습) PDF 내용 요약하여 출력하기

2. 코드 실행 후 output 폴더에 생성된

파일 열기



```
crop_model_summary2.txt
# 과정기반 작물모형을 이용한 웹 기반 밀 재배관리 의사결정 지원시스템 설계 및 구축

## 저자의 문제 인식 및 주장 (15문장 이내)
- 우리나라의 밀 자급률은 약 1%에 불과하고, 밀 소비량이 증가하고 있어 안정적 재배 기반이 필요하다.
- 밀 자급률 제고를 위해서는 가격 경쟁력과 품질 향상이 중요하며, 재배 면적 확대와 생산성 향상이 필수적이다.
- 노지 재배 작물은 기상조건을 인위적으로 조절하기 어렵고 외부 요인에 따라 생산량이 크게 달라진다.
- 지역별 경지면적 차이와 토양 특성은 일관된 재배환경 형성을 어렵게 한다.
- 노동력 감소와 생산성 향상을 목표로 디지털 농업의 도입 필요성이 커지고 있다.
- 과정기반 작물모형은 생리작용과 환경 요인의 관계를 시계열로 모의해 다양한 시나리오를 분석하는 데 강점이 있다.
- APSIM은 오픈소스 모듈형 프레임워크로, 다양한 환경에서 작물생육을 예측하는 데 적합하다.
- 본 연구는 APSIM 기반의 웹 기반 의사결정 지원시스템을 설계·구축하여 재배단계별 의사결정에 도움을 주고자 한다.
- 시스템은 과거·현재 기상데이터를 이용해 현재 상태의 생산량을 추정하고, 과거 40년 데이터를 바탕으로 미래 기상 시나리오를 만들어 잠재수확량을 예측한다.
- 대시보드 형태의 웹 인터페이스를 통해 사용자의 편의성을 높이고, 과거·현재·미래의 조건에 따른 수확량 변화를 시각화한다.
- 이 시스템은 10년 주기의 자연재난을 고려한 피해 규모의 예측도 가능하도록 설계되었다.
- APSIM의 한계로는 해충과 질병의 영향을 직접 모델링하기 어렵다는 점이 있다.
- 현장 재배실험 데이터를 바탕으로 APSIM 파라미터를 보정하고, 파종일부터 수확까지의 생육단계를 반영하는 모델을 구축하였다.
- 실험 포장에서 수집된 토양과 기상 데이터를 이용해 토양수분 파라미터를 세부적으로 설정하고, 토양 수분과 광량 등 변수를 분석한다.
- 본 연구의 시스템은 전국적 적용 가능성을 갖고 있으며, 향후 질소 등 추가 요인을 포함해 예측 정확도를 높일 수 있다.

## 저자 소개
- 김솔희a, Assistant Research Professor, Department of Smart Farm, Jeonbuk National University
- 석승원b, Undergraduate, Department of Smart Farm, Jeonbuk National University
- 청리광c, Ph.D. Student, Department of Rural Construction Engineering, Jeonbuk National University
- 장태일d, Professor, Department of Rural Construction Engineering, Institute of Agricultural Science & Technology, Jeonbuk National University
- 김태곤e, Assistant Professor, Department of Smart Farm, Jeonbuk National University
- † corresponding author: Taegon Kim (taegon@jbnu.ac.kr)

===== 이하 텍스트 =====

줄 1, 열 1 | 1,598자 | 일반 텍스트 | 100% | Windows (CRLF) | UTF-8
```