


선형 회귀분석

선형 회귀분석의 개념

● 선형 회귀분석의 모형

- 선형 회귀분석(Linear regression analysis) :
두 개 또는 그 이상의 변수 간 인과관계의 패턴을 원래 모습과 가장 가깝게 추정하는 분석 방법.
- 함수 $y = 2x + 80$ 의 그래프, 이를 선형 회귀분석의 모형(Model)이라고 부름.
- 선형 회귀분석은 x 변수가 원인, y 변수가 결과로 인과관계여야 한다는 조건 있음.




선형 회귀분석 그래프 ©BU School of Public Health

선형 회귀분석의 개념

● 선형 회귀분석의 모형

- 회귀분석에서 원인인 x 변수는 독립변수(Independent variable), 결과인 y 변수는 종속변수(Dependent variable)라고 부름.
- 어떠한 결과의 원인이 되는 독립변수가 한 개일 때 단순 선형 회귀분석(Simple linear regression analysis), 두 개 이상이면 다중 선형 회귀분석(Multiple linear regression analysis).
- 공부 시간과 시험 점수의 인과관계를 분석해보면 종속변수는 시험 점수이며 독립변수는 공부 시간만 고려.



선형 회귀분석 그래프

선형 회귀분석의 개념


● 선형 회귀분석의 모형

- [그림 10-2]의 점들을 직선 하나로 표현하고자 함.
- 직선을 일차함수 $y = mx + b$ 로 표현한다면 계수 m 은 이 직선의 기울기이므로 양수일 것.
- 일반적인 선형 회귀모형은 다음 식과 같이 독립변수 x_i 앞에 계수 β_i 가 붙음.
마지막 ϵ 은 오차 항.

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3 + \cdots + \epsilon$$

$\beta_i : x_i$ 의 계수 오차


- 데이터를 표현하는 직선은 여러 개 존재할 수 있음.



선형 회귀분석의 개념

● 선형 회귀분석의 모형

- 최대한 많은 점과 거리가 가까운 직선이 좋은 직선.
- 아래 그림에서와 같이 점에서 직선까지 y축과 평행한 선분을 그렸을 때 모든 선분 길이의 합을 최소로 하는 직선을 찾는 것.



- 점이 가리키는 값과 직선이 예측하는 값의 차를 잔차(Residual)라고 부름.

선형 회귀분석의 개념

● 선형 회귀분석의 모형

• 더미 변수

- 더미 변수(Dummy variable)는 독립변수를 0과 1로 변환하여 '예'와 '아니오'로 나타낼 수 있는 변수.
- 더미 변수를 여러 개 두면 '예'와 '아니오'만으로 결과를 세 가지 이상으로 구분할 수 있음.
- 아래 표와 같이 어린이, 청소년, 성인으로 구분.
 - ① 데이터가 어린이일 때 '어린이' 더미 변수는 1이고 '청소년' 더미 변수는 0.
 - ② 청소년일 때 '어린이' 더미 변수는 0이고 '청소년' 더미 변수는 1.
 - ③ 어린이도 청소년도 아닌 성인은 두 더미 변수에 모두 0을 대입하여 표현할 수 있음.

따라서 구분하고자 하는 데이터의 종류가 N개일 때 더미 변수 N-1개를 선언하면 됨.

	어린이 더미 변수	청소년 더미 변수
어린이	1	0
청소년	0	1
성인	0	0

선형 회귀분석의 개념

- 선형 회귀분석의 모형

- 결정계수

- 선형 회귀분석에서 모형이 데이터의 패턴을 얼마나 효과적으로 보여주는지 수치화한 값을 결정계수라고 함.
 - 결정계수 R^2 (R square)를 다음 수식과 같이 정의.

$$R^2 = \frac{(Q - Q_e)}{Q}$$

Q = 전체 데이터의 편차 제곱의 합


Q_e = 전체 데이터의 잔차 제곱의 합

선형 회귀분석의 개념


● 선형 회귀분석의 모형

• 결정계수


- 편차(Deviation)는 평균과 실제 값의 차이.
- 결정계수 R^2 는 0 이상 1 이하의 값으로 계산됨.
- R^2 값이 1에 가까울 때 잔차가 작고 예측의 정밀도가 높음.
반면 R^2 값이 0에 가까울 때 잔차가 커 예측의 정밀도가 낮음.



(a) R^2 가 1에 가까운 경우



(b) R^2 가 0.5에 가까운 경우



(c) R^2 가 0에 가까운 경우

선형 회귀분석의 개념

- 선형 회귀분석의 모형

- 수정된 결정계수
 - 결정계수 R^2 는 독립변수의 개수가 많을수록 커지는 경향을 보임.
 - 이러한 문제를 해결하기 위해 다중 선형 회귀분석에서 수정된 결정계수 $adj. R^2$ (adjusted R square)로 설명력을 나타냄.

$$adj. R^2 = \frac{(n - 1)}{(n - p - 1)(1 - R^2)}$$

R^2 = 결정계수, p = 독립변수의 개수, n = 표본 수

선형 회귀분석의 개념

- 선형 회귀분석의 해석

- 통계적 가설검정

- 모집단에 대한 추측을 하고 표본의 정보를 기준으로 가설이 타당한지 판정하는 방법.
 - 통계적 가설에는 두 종류가 있음.
 - 통계학에서 처음부터 거짓일 것으로 기대하는 가설인 귀무가설(Null hypothesis)
 - 입증하고자 하는 가설인 대립가설(Alternative hypothesis)
 - 실험 결과를 보고 귀무가설을 채택하거나 대립가설을 채택하는 기준을 세워 두어야 하고, 그 기준을 유의수준(Significance level)이라고 함.
 - 귀무가설이 참일 때 실제 결과가 실험 결과와 같을 확률은 p-값(p-value, 유의확률)이라고 부름.

선형 회귀분석의 개념

- 선형 회귀분석의 해석

- 선형 회귀분석 과정

- 선형 회귀분석을 수행하고 해석하는 과정은 크게 세 단계

- ① 결과인 종속변수를 y 로 두고, 원인이 되는 독립변수를 x_i 로 둬.
- ② 설명력 R^2 또는 $\text{adj.}R^2$ 값을 확인. 결정계수가 0.6 또는 0.4 이상이면 해당 회귀모형이 설명력을 갖추었다고 인정.
- ③ 각 독립변수의 p -값이 유의수준보다 작은지 확인. p -값이 유의수준 이상인 변수를 제외하고 남은 독립변수가 결과에 영향을 주는 원인.

선형 회귀분석의 활용

- 연봉과 직장 만족도
 - 연봉이 직장 만족도와 얼마나 관계 있는지 파악할 수 있음.


직장 만족도(점)	60	75	70	85	90	70	65	95	70	80
연봉(만 원)	3,000	4,200	4,000	5,000	6,000	3,800	3,500	6,200	3,900	4,500

- 원인인 독립변수는 연봉이며 결과인 종속변수는 직장 만족도.

선형 회귀분석의 활용

- 연봉과 직장 만족도

실행결과



- 리스트 x에 독립변수인 연봉을 할당, 리스트 y에 종속변수인 직장 만족도를 할당.
- 맷플롯립의 scatter() 함수로 산점도를 그리면 산점도는 우상향 형태로 나타남.

선형 회귀분석의 활용

- 연봉과 직장 만족도

- 산점도를 보면 두 변수에 양의 상관관계가 있음을 알 수 있는데, 인과관계가 얼마나 강한지 선형 회귀분석으로 확인하려함.
- 선형 회귀모형은 다음과 같은 형태로 설정.

종속변수 ~ 독립변수1 + 독립변수2 + 독립변수3 + ...

- `ols()` 함수는 선형 회귀분석을 수행하는 함수. 첫 번째 인자로 회귀모형 'y ~ x', 두 번째 인자로 데이터를 입력.

선형 회귀분석의 활용

- 연봉과 직장 만족도

실행결과

OLS Regression Results					
=====					
Dep. Variable:	y	R-squared:	0.971		
Model:	OLS	Adj. R-squared:	0.968		
Method:	Least Squares	F-statistic:	271.0		
Date:	Mon, 27 Mar 2023	Prob (F-statistic):	1.87e-07		
Time:	07:13:44	Log-Likelihood:	-20.111		
No. Observations:	10	AIC:	44.22		
Df Residuals:		8	BIC:	44.83	
Df Model:	1				
Covariance Type:	nonrobust				
=====					
	coef	std err	t	P> t	[0.025 0.975]

Intercept	29.0004	2.926	9.913	0.000	22.254 35.747
x	0.0107	0.001	16.463	0.000	0.009 0.012
=====					
Omnibus:	0.346	Durbin-Watson:	2.871		
Prob(Omnibus):	0.841	Jarque-Bera (JB):	0.447		
Skew:	0.286	Prob(JB):	0.800		
Kurtosis:	2.136	Cond. No.	2.07e+04		
=====					

선형 회귀분석의 활용

● 연봉과 직장 만족도

- 첫째, 결정계수 R^2 값이 0.971이므로 표본 데이터들에 대한 설명력이 97.1%이고, 결정계수가 0.6을 크게 초과하므로 모형의 정밀도가 높음.
- 둘째, 회귀모형의 독립변수 x 의 유의수준은 0.000으로 0.05 미만이므로 x 는 유의한 독립변수.
- 셋째, 독립변수 x 의 계수는 0.0107.

$$y = 29.0004 + (0.0107) \times x + \varepsilon$$

선형 회귀분석의 활용

- 직장 만족도의 요인 분석

- 연봉 외에 일평균 휴식시간(분)과 일평균 근무시간(시간) 추가하여 각 변수의 영향을 분석.

직장 만족도(점)	60	75	70	85	90	70	65	95	70	80
연봉(만 원)	3,000	4,200	4,000	5,000	6,000	3,800	3,500	6,200	3,900	4,500
일평균 휴식시간(분)	120	60	100	100	50	120	90	40	120	120
일평균 근무시간(시간)	8	6	10	8	10	10	9	7	8	9

- 결과인 직장 만족도가 종속변수이며, 나머지는 독립변수.
- 회귀모형 `companySatisfaction ~ salary + breakTime + workingTime`을 입력하여 다중 선형 회귀분석을 수행.

선형 회귀분석의 활용

- 직장 만족도의 요인 분석

실행결과

OLS Regression Results					
=====					
Dep. Variable:	companySatisfaction		R-squared: 0.988		
Model:	OLS		Adj. R-squared: 0.982		
Method:	Least Squares		F-statistic: 164.0		
Date:	Mon, 27 Mar 2023		Prob (F-statistic): 3.81e-06		
Time:	07:30:46		Log-Likelihood: -15.777		
No. Observations:	10		AIC: 39.55		
Df Residuals:	6		BIC: 40.77		
Df Model:	3				
Covariance Type:	nonrobust				
=====					
	coef	std err	t	P> t	[0.025 0.975]

Intercept	24.9819	5.353	4.667	0.003	11.884 38.080
salary	0.0120	0.001	15.895	0.000	0.010 0.014
breakTime	0.0668	0.027	2.491	0.047	0.001 0.132
workingTime	-0.9718	0.412	-2.356	0.057	-1.981 0.037
=====					
Omnibus:	0.929	Durbin-Watson:		2.500	
Prob(Omnibus):	0.628	Jarque-Bera (JB):		0.752	
Skew:	-0.441	Prob(JB):		0.686	
Kurtosis:	1.986	Cond. No.		5.06e+04	
=====					

선형 회귀분석의 활용

● 직장 만족도의 요인 분석

- 첫째, 수정된 결정계수 $adj. R^2$ 는 0.988이므로 이 선형 회귀모형의 설명력이 98.8%
- 둘째, 변수 salary는 p-값이 0.000이고 변수 breakTime은 0.047로 0.05 보다 작고 workingTime의 p-값은 0.057로 0.05 보다 큼. 따라서 연봉과 휴식시간은 유의한 독립변수이고, 근무시간은 유의하지 않은 독립변수.
- 셋째, 유의수준 결과에 따라서 salary와 breakTime을 독립변수로 하는 모형이 구성됨.

companySatisfaction

$$= 24.9819 + (0.0120) \times salary + (0.0668) \times breakTime + \varepsilon$$