

로지스틱 회귀분석

로지스틱 회귀분석의 개념


● 로지스틱 회귀모형

- 로지스틱 회귀분석(Logistic regression analysis)은 결과인 종속변수에 미치는 요인들을 독립변수로 두고 각 독립변수의 영향을 설명.
- 로지스틱 회귀분석의 종속변수는 범위에 제한이 있음.
- 로지스틱 회귀분석의 종속변수는 0에서 1사이의 값.


로지스틱 회귀분석의 개념

● 로지스틱 회귀모형

- 아래 그림은 선형 회귀분석과 로지스틱 회귀분석의 모형.
- 왼쪽의 선형 회귀분석은 표본 데이터를 직선으로 그룹화.
- 반면 오른쪽의 로지스틱 회귀분석은 표본 데이터가 0에서 1사이의 값으로 그룹화되어 있음.



(a) 선형 회귀분석



(b) 로지스틱 회귀분석

로지스틱 회귀분석의 개념

● 로지스틱 회귀모형

- 로지스틱 회귀분석 결과 오즈비를 얻음. 오즈비(Odds Ratio, OR)는 우리말로 승산비.
- 사건이 발생할 확률을 p 라고 할 때, 오즈비를 수식으로 나타내면 다음과 같음.

$$OR = \frac{\text{사건이 발생할 확률}}{\text{사건이 발생하지 않을 확률}} = \frac{p}{1-p}$$

- 대학 합격이라는 사건에서 합격을 1, 불합격을 0으로 정했을 때 합격할 확률이 0.8이라면 오즈비는 4. 이는 대학에 합격할 확률이 불합격할 확률보다 4배 높다는 뜻.

$$OR = \frac{p}{1-p} = \frac{0.8}{1-0.8} = 4$$

로지스틱 회귀분석의 개념

● 로지스틱 회귀분석의 해석

- 로지스틱 회귀분석의 해석 과정은 다음과 같음.
 - 첫째, 선형 회귀분석과 마찬가지로 각 독립변수의 p-값을 확인함. p-값이 유의수준보다 작은 독립변수를 통계적으로 유의한 변수라고 판단.
 - 둘째, 오즈비를 구해 각 독립변수가 종속변수를 1로 만들 확률을 비교.
- 사과 가격이 사과 판매 여부에 미치는 영향을 분석해보기. 종속변수는 사과 판매 여부로, 사과가 판매되면 1이고 판매되지 않으면 0. 독립변수는 사과 가격.

사과 판매 여부	1	1	1	1	1	1	1	1	1
가격(원)	1,500	2,000	5,000	3,000	3,500	2,500	4,000	4,500	3,000
사과 판매 여부	0	0	0	0	0	0	0	0	
가격(원)	4,500	4,000	4,500	5,500	6,500	5,000	3,500	7,000	

로지스틱 회귀분석의 개념

- 로지스틱 회귀분석의 해석

실행결과

```
Optimization terminated successfully.
Current function value: 0.430873
Iterations 7

Logit Regression Results
=====
Dep. Variable:      sales      No. Observations:      17
Model:              Logit      Df Residuals:           15
Method:              MLE        Df Model:              1
Date:               Mon, 03 Apr 2023      Pseudo R-squ.:         0.3768
Time:               00:48:37      Log-Likelihood:        -7.3248
converged:           True        LL-Null:              -11.754
Covariance Type:     nonrobust      LLR p-value:           0.002917
=====
              coef      std err      z      P>|z|      [0.025 0.975]
-----
Intercept      6.5752      3.300      1.993      0.046      0.108 13.042
price      -0.0016      0.001     -2.008      0.045     -0.003 3.75e-05
=====
OR
Intercept 717.058841
price 0.998433
dtype: float64
```

로지스틱 회귀분석의 개념

- 로지스틱 회귀분석의 해석

- 우선 각 독립변수가 유의한지 확인.
- 독립변수 price의 p-값은 0.04로 0.05 미만이므로 유의한 변수.
- y절편인 Intercept의 p-값 0.046도 확인할 수 있음.
- 변수 price의 오즈비가 0.998433이므로 가격을 올렸을 때 판매될 가능성이 판매되지 않을 가능성의 0.998433배.

로지스틱 회귀분석의 활용

- 타이타닉 탑승자 생존여부 예측
 - 타이타닉호 데이터에서 생존과 사망의 요인을 분석해보기.

타이타닉 탑승자 데이터

	survived	pclass	sex	age	sibsp	parch	fare	embarked	class \
0	0	3	male	22.0	1	0	7.2500	S	Third
1	1	1	female	38.0	1	0	71.2833	C	First
2	1	3	female	26.0	0	0	7.9250	S	Third
3	1	1	female	35.0	1	0	53.1000	S	First
4	0	3	male	35.0	0	0	8.0500	S	Third
..	...	...	...	...	...	...	...	...	...
886	0	2	male	27.0	0	0	13.0000	S	Second
887	1	1	female	19.0	0	0	30.0000	S	First
888	0	3	female	NaN	1	2	23.4500	S	Third
889	1	1	male	26.0	0	0	30.0000	C	First
890	0	3	male	32.0	0	0	7.7500	Q	Third

로지스틱 회귀분석의 활용

● 타이타닉 탑승자 생존여부 예측

실행결과(계속)

	who	adult_male	deck	embark_town	alive	alone
0	man	True	NaN	Southampton	no	False
1	woman	False	C	Cherbourg	yes	False
2	woman	False	NaN	Southampton	yes	True
3	woman	False	C	Southampton	yes	False
4	man	True	NaN	Southampton	no	True
..	...	...	...	...	...	...
886	man	True	NaN	Southampton	no	True
887	woman	False	B	Southampton	yes	True
888	woman	False	NaN	Southampton	no	False
889	man	True	C	Cherbourg	yes	True
890	man	True	NaN	Queenstown	no	True

```
[891 rows x 15 columns]
```

로지스틱 회귀분석의 활용

- 타이타닉 탑승자 생존여부 예측

실행 결과

```
Optimization terminated successfully.
      Current function value: 0.445244
      Iterations 6

Logit Regression Results
=====
Dep. Variable:      survived      No. Observations:      714
Model:              Logit        Df Residuals:           707
Method:             MLE          Df Model:                6
Date:               Mon, 03 Apr 2023      Pseudo R-squ.:         0.3408
Time:               00:59:54             Log-Likelihood:        -317.90
converged:          True             LL-Null:               -482.26
Covariance Type:    nonrobust          LLR p-value:           5.727e-68
=====
              coef      std err      z      P>|z|      [0.025 0.975]
-----
Intercept      5.3890      0.604      8.926      0.000      4.206 6.572
pclass        -1.2422      0.163     -7.612      0.000     -1.562 -0.922
sex            -2.6348      0.220    -11.998      0.000     -3.065 -2.204
age            -0.0440      0.008     -5.374      0.000     -0.060 -0.028
fare           0.0022      0.002      0.866      0.386     -0.003 0.007
parch          -0.0619      0.123     -0.504      0.614     -0.303 0.179
sibsp          -0.3758      0.127     -2.950      0.003     -0.625 -0.126
=====
```

로지스틱 회귀분석의 활용

- 타이타닉 탑승자 생존여부 예측

- 첫째, 독립변수 중 p-값이 0.05 미만인 변수는 pclass, sex, age, sibsp.
- 이들 변수의 계수가 모두 음수이므로 독립변수의 값이 증가할 때 생존 가능성이 낮아지는 것으로 판단.
- 둘째, 유의한 독립변수 중 age의 오즈비가 가장 크고, sex의 오즈비가 가장 작음.