

서포트 벡터머신


(Support Vector Machine, SVM)

서포트 벡터머신(Support Vector Machine, SVM)

- 사용하기 편하면서도 높은 정확도를 보이는 데이터 분류를 위한 지도학습 머신러닝 알고리즘.
- 서포트 벡터를 사용해서 결정 경계를 정의하고, 분류되지 않은 점을 해당 결정 경계와 비교해서 분류.
- SVM의 중요 용어
 - 결정 경계(Decision Boundary) : 서로 다른 분류 값을 결정하는 경계.
 - 서포트 벡터(support vector) : 결정 경계선과 가장 가까이 맞닿은 데이터 포인트(클래스의 점 들).
 - 마진(margin) : 서포트 벡터와 결정 경계 사이의 거리.
- SVM의 목표는 바로 이 마진을 최대로 하는 결정 경계를 찾는 것.


서포트 벡터머신 - 결정 경계(선)

- 데이터에 2개 속성(feature)만 있다면 결정 경계는 이렇게 간단한 선 형태



서포트 벡터머신 - 결정 경계(면)

- 속성이 3개로 늘어난다면 이렇게 3차원으로 그려야 한다.




- 이때의 결정 경계는 '선'이 아닌 '평면'이 된다.
- 우리가 이렇게 시각적으로 인지할 수 있는 범위는 딱 3차원까지다.
- 차원, 즉 속성의 개수가 늘어날수록 당연히 복잡
- 결정 경계도 단순한 평면이 아닌 고차원이 될 텐데 이를 “초평면 (hyperplane)”이라고 부른다.

서포트 벡터머신 - 결정 경계

- 최적의 결정 경계(Decision Boundary)

Different Decision Boundaries



서포트 벡터머신 - 결정 경계


- 최적의 결정 경계(Decision Boundary)

- 어떤 그래프가 제일 위태로워 보이는가?
 - C를 보면 선이 파란색 부류와 너무 가까워서 아슬아슬해 보인다.
- 그렇다면 어떤 결정 경계가 가장 적절해 보이는가?
 - 당연히 F다. 두 클래스(분류) 사이에서 거리가 가장 멀기 때문이다.
- 결정 경계는 데이터 군으로부터 최대한 멀리 떨어지는 게 좋다는 걸 알았다.
- 실제로 서포트 벡터 머신(Support Vector Machine)이라는 이름에서 Support Vectors는 결정 경계와 가까이 있는 데이터 포인트들을 의미한다.
- 이 데이터들이 경계를 정의하는 결정적인 역할을 하는 셈이다.

서포트 벡터머신 - 마진

➤ 마진(Margin)


- 결정 경계와 서포트 벡터 사이의 거리를 의미한다.




- 가운데 실선이 하나 그어져있는데, 이게 바로 '결정 경계'
- 그리고 그 실선으로부터 검은 테두리가 있는 빨간점 1개, 파란점 2개까지 영역을 두고 점선을 그어놓았다. 이게 바로 '마진(margin)'
- **최적의 결정 경계는 마진을 최대화한다.**
- 옆 그림에서는 x축과 y축 2개의 속성을 가진 데이터로 결정 경계를 그었는데, 총 3개의 데이터 포인트(서포트 벡터)가 필요했다. 즉, n 개의 속성을 가진 데이터에는 최소 $n+1$ 개의 서포트 벡터가 존재한다는 걸 알 수 있다.

서포트 벡터머신 - 커널 트릭

- 1차원의 데이터 결정 경계 찾기



- 2차원 공간으로 옮겨진 데이터 결정 경계 찾기



결정 경계선


- $y = x^2$

- 매핑 함수: 저차원의 데이터를 고차원의 데이터로 옮겨주는 함수.

서포트 벡터머신 - 커널 트릭

- 커널 트릭(kernel trick)

- 매핑 함수를 가지고 실제로 많은 양의 데이터를 저차원에서 고차원으로 옮기기에는 계산량이 너무 많아서 현실적으로 사용하기가 어려움.
- 데이터를 고차원으로 보내진 않지만 보낸 것과 동일한 효과를 줘서 매우 빠른 속도로 결정 경계선을 찾는 방법.
- 저차원에서 결정 경계를 찾지 못할 때 고차원으로 데이터(벡터)를 옮겨서 결정 경계를 찾는 방법.




서포트 벡터머신 - 파라미터 튜닝

- 결정 경계 = $N - 1$ 차원 (단, 데이터의 벡터 공간은 N 차원)
- 따라서, 2차원 공간의 결정 경계는 선, 3차원 공간의 결정 경계는 면.
- 파라미터 C (cost, 비용)는 허용되는 오류 양을 조절.
 - 마진의 너비를 조정하는 파라미터.
 - C 값이 클수록, 마진은 낮아지고, 학습 에러율은 감소하는 방향으로 결정 경계선을 만들고, 이를 **하드 마진(hard margin)**이라 부름 - 너무 높으면 과대 적합의 위험.
 - C 값이 작을수록, 마진을 최대한 높이고, 학습 에러율을 증가시키는 방향으로 결정 경계선을 만들어서 **소프트 마진(soft margin)**을 만듦 - 너무 낮으면 과소 적합의 위험.

서포트 벡터머신 - 파라미터 튜닝


- SVM에서는 선형으로 분리할 수 없는 점들을 분류하기 위해 커널(kernel)을 사용.
- 커널(kernel)은 원래 가지고 있는 데이터를 더 높은 차원의 데이터로 변환.
 - 2차원의 점으로 나타낼 수 있는 데이터를
 - 다항식(polynomial) 커널은 3차원으로,
 - RBF(Radial Basis Function) 커널은 점을 무한한 차원으로 변환.
- RBF 커널에는 파라미터 감마(gamma)가 있음.
 - 커널의 데이터포인트 표준 편차를 결정하는 조절 변수.
 - 감마가 너무 크면 학습 데이터에 너무 의존해서 오버피팅이 발생할 수 있다.
- 대부분의 머신러닝 지도 학습 알고리즘은 학습 데이터 모두를 사용하여 모델을 학습.
 - SVM에서는 결정 경계를 정의하는 게 결국 서포트 벡터이기 때문에, 데이터 포인트 중에서 서포트 벡터만 잘 골라내면 나머지 쓸 데 없는 수많은 데이터 포인트들을 무시할 수 있음.
 - 그래서 매우 빠르다.

서포트 벡터머신 - 파라미터 튜닝




서포트 벡터머신 - 파라미터 튜닝


gamma=0




gamma=10




gamma=100




c=1



C=100



c=1000



서포트 벡터머신 - 장/단점

● 장점

- 커널 트릭을 사용함으로써 특성이 다양한 데이터를 분류하는 데 강하다.
 - N개의 특성을 가진 데이터는 N차원 공간의 데이터 포인트로 표현되고, N차원 공간 또는 그 이상의 공간에서 초평면을 찾아 데이터 분류가 가능하기 때문.
- 예측 속도가 빠르다.
- 파라미터(C, gamma)를 조정해서 과대적합 및 과소적합에 대처할 수 있다.
- 적은 학습 데이터로도 딥러닝만큼 정확도가 높은 분류를 기대할 수 있다.

● 단점

- 데이터 전처리 과정(data preprocessing)이 상당히 중요하다.
 - 특성이 비슷한 수치로 구성된 데이터 같은 경우에는 SVM을 쉽게 활용할 수 있지만, 특성이 다양하거나 혹은 확연히 다른 경우에는 데이터 전처리 과정을 통해 데이터 특성 그대로 벡터 공간에 표현해야 함.
- 특성이 많을 경우 결정 경계 및 데이터의 시각화가 어려움 - SVM의 분류 결과를 이해하기 힘들.
- 커널 트릭 오사용시 과대적합되기 쉽다.