


의사결정 트리

(Decision Tree)

의사결정 트리(Decision Tree)



의사결정 트리(Decision Tree)

- 데이터 분류 및 회귀에 사용되는 지도학습 알고리즘.
- 데이터의 특징 속에서 분류에 큰 영향을 끼치는 특징을 발견하고, 상위 노드로 선택하는 알고리즘.
- 머신러닝에서 의미 있는 질문이란 데이터의 특징 중 의미 있는 특징에 해당하며, 의사결정트리의 핵심은 바로 영향력이 큰 특징을 상위 노드로, 영향력이 작은 특징은 하위 노드로 선택하는 것.
- 데이터가 주어졌을 때 의사결정 트리는 어떻게 특징별 영향력의 크고 작음을 비교할 수 있을까?
 - 크고 작음을 비교하기 위해 수치적인 결과가 필요.

의사결정 트리 알고리즘과 정보 엔트로피의 관계

- 스무고개를 할 때 질문자는 질문을 던질 때마다 약간씩의 정보를 획득.
- 약간씩의 정보를 획득하는 과정은 정답에 대한 불확실성이 조금씩 줄어든다는 것과 같은 개념.
- 엔트로피(Entropy) : 정보 이론(Information Theory)에서는 이 불확실성을 수치적으로 표현한 값.
- 정보 이득(information gain) : 불확실성이 줄어 든 정도. 즉 질문 이전의 엔트로피에서 질문 후의 엔트로피를 뺀 값.
 - $Gain(T, X) = Entropy(T) - Entropy(T, X)$
- 확률을 바탕으로 정보 엔트로피를 구하는 공식
 - $Entropy = \sum_{i=1}^n -p_i \log_2 p_i$

의사결정 트리 사례로 정보 엔트로피 구하기

이름	군필	긴생머리	성별
김철수	네	아니오	남자
이영희	아니오	아니오	여자
홍길동	네	아니오	남자
최빛나	아니오	네	여자
강감찬	네	아니오	남자
유관순	아니요	아니오	여자

- 엔트로피 = $-p(\text{남자}) * \log(p(\text{남자})) - p(\text{여자}) * \log(p(\text{여자}))$
- 의사결정 트리의 최초 엔트로피는 1이며, 계산 방법은
 - $-(3/6) * \log(3/6) - (3/6) * \log(3/6) = 1$

한 가지 특징에 대한 엔트로피 계산

$$Entropy = \sum_{c \in X} P(c)E(c)$$

- X : 선택된 특징.
- c : 선택된 특징에 의해 생성된 하위 노드.
- $P(c)$: 선택된 특징에 의해 생성된 하위 노드에 데이터가 속할 확률.
- $E(c)$: 선택된 특징에 의해 생성된 하위 노드의 엔트로피.

- 군대라는 특징으로 데이터를 분리했을 때의 엔트로피

$$\begin{aligned} & 3/6 * E[3,0] + 3/6 * E[0,3] \\ &= 3/6 * (-(3/3) * \log(3/3) - (0/3) * \log(0/3)) + 3/6 * (-(0/3) * \log(0/3) - (3/3) * \log(3/3)) \\ &= 0 \end{aligned}$$

- 긴 생머리라는 특징으로 데이터를 분리했을 때의 엔트로피

$$\begin{aligned} & 1/6 * E[0,1] + 5/6 * E[3,2] \\ &= 1/6 * (-(0/1) * \log(0/1) - (1/1) * \log(1/1)) + 5/6 * (-(3/5) * \log(3/5) - (2/5) * \log(2/5)) \\ &= 0.8091 \end{aligned}$$

- “군대”로 데이터를 분리할 때의 정보 이득 : 1

- “긴 생머리”로 데이터를 분리할 때의 정보 이득 : 0.191

지니 계수(Gini coefficient)

- 특징에 의한 분리가 이진 분류로 나타날 경우 지니 계수를 사용할 수 있음.
- 사이킷런의 의사결정 트리는 CART(classification and regression tree) 타입의 의사결정 트리.
- CART는 트리의 노드마다 특징을 이진 분류하는 특징이 있기에 사이킷런은 트리를 구성할 때 기본적으로 지니 계수를 사용.
- 지니 계수의 특징
 - 특징이 항상 이진 분류로 나뉘는 때 사용됨.
 - 지니 계수가 높을수록 불순도가 높음.
 - 순도가 높다는 뜻: 한 그룹에 모여있는 데이터들의 속성들이 많이 일치한다는 뜻.
 - 불순도가 높다는 뜻: 한 그룹에 여러 속성의 데이터가 많이 섞여 있다는 뜻.
- 의사결정 트리 알고리즘은 지니 계수가 높은 특징으로 의사결정 트리 노드를 결정.

지니 계수를 통한 의사결정 트리 노드 결정 순서

1. 특징으로 분리된 두 노드의 지니 계수를 구함($P^2 + Q^2$)
2. 특징에 대한 지니 계수를 구함.

예) 군대라는 특징으로 “군대를 다녀옴”, “다녀오지 않음”으로 구분할 경우 지니 계수

- 군대를 다녀옴 : $(3/3)^2 + (0/3)^2 = 1$
- 군대를 다녀오지 않음 : $(0/3)^2 + (3/3)^2 = 1$
- 군대 특징의 지니 계수 : $3/6 * 1 + 3/6 * 1 = 1$


예) 긴 생머리를 특징으로 “긴 생머리”, “긴 생머리 아님”으로 구분할 경우 지니 계수

- 긴생머리 : $(0/1)^2 + (1/1)^2 = 1$
- 긴생머리 아님 : $(3/5)^2 + (2/5)^2 = 13/25$
- 긴생머리 특징의 지니 계수 : $1/6 * 1 + 5/6 * 13/25 = 0.6$

다중 분류

- 서울시 행정구역에 대한 다중 분류 데이터 시각화

- 데이터를, 특징을 바탕으로 한 공간에 데이터 특징을 시각화함으로써, 우리는 머신러닝 학습에 필요한 특징과 불필요한 특징을 쉽게 구분 지을 수 있고, 데이터의 패턴을 눈으로 쉽게 파악할 수 있음.



다중 분류

● 문제 정의

- 서울 지역(구)의 경도와 위도 정보를 사용하여, 임의로 입력된 지역(동)을 강동, 강서, 강남, 강북으로 분류해보는 예제

● 데이터 수집


- 서울의 대표적인 구(district) 위치 데이터
- 구(district) 정보는 학습에 사용

● 컬럼 주석

- **district**: 행정구역 (서초구, 송파구, 용산구 등, 서울의 단위 지역 분류)
- **dong**: 구(district)보다 작은 행정구역 (대치동, 도곡동, 암사동 등, 서울의 소단위 분류)
- **longitude**: 경도
- **latitude**: 위도
- **label**: 한강 기준으로 동, 서, 남, 북으로 구분한 지역 명칭(강동, 강서, 강남, 강북)


파라미터 없이 학습한 모델의 결정 표면 시각화

- 사이킷런의 의사결정 트리 알고리즘 적용 시, 특별히 파라미터를 설정하지 않고 학습할 경우 모델은 과대 적합 될 가능성이 높다.



파라미터 설정한 모델의 결정 표면 시각화

● 사이킷런의 의사결정 트리 모델




```
clf = tree.DecisionTreeClassifier(  
    max_depth=4,  
    min_samples_split=2,  
    min_samples_leaf=2,  
    random_state=70).fit(X_train, y_encoded.ravel())
```

- **max_depth** : 트리의 최대 한도 깊이.
- **min_samples_split** : 자식 노드를 갖기 위한 최소한의 데이터 개수.
- **min_samples_leaf** : 맨 마지막 끝 노드의 최소 데이터 개수.
- **random_state** : 여러 번 실행해도, 파라미터가 같을 경우, 결과가 항상 같게 만들어주는 파라미터.

의사결정 트리 시각화

● 의사결정트리 시각화



- **gini** : 불순도 척도. 0일 경우 모든 샘플이 하나의 레이블을 가지며, 1에 가까울수록 여러 레이블이 한 노드에 존재함.
- **samples** : 노드 안에 들어 있는 데이터의 개수.
- **value** : 레이블별 데이터의 개수.
- **class** : 레이블.

의사결정 트리 - 장/단점

● 장점

- 수학적 지식이 없어도 결과를 해석하고 이해하기 쉽다.
- 수치 데이터 및 범주 데이터에 모두 사용 가능하다.
- 모델의 추론 과정을 시각화하기 쉽다.
- 데이터에서 중요한 특성이 무엇인지 쉽게 알아낼 수 있다.

● 단점

- 과대적합의 위험이 높다.
 - 의사결정 트리 학습 시 적절한 리프 노드의 샘플 개수와 트리의 깊이에 제한을 두어서 학습 데이터에 너무 모델이 치우치지 않게 주의.
- 조정해야 할 하이퍼 파라미터가 많다.