

나이브 베이즈 (Naïve Bayes)

나이브 베이즈(Naïve Bayes)

- 확률 기반 머신러닝 분류 알고리즘.
- 데이터를 나이브(단순)하게 독립적인 사건으로 가정하고, 이 독립 사건들을 베이즈 이론에 대입시켜 가장 높은 확률의 레이블로 분류를 실행하는 알고리즘.
- 베이즈 이론


$$P(A | B) = \frac{P(B|A) P(A)}{P(B)}$$

- $P(A | B)$: 어떤 사건 B가 일어났을 때 사건 A가 일어날 확률.
- $P(B | A)$: 어떤 사건 A가 일어났을 때 사건 B가 일어날 확률.
- $P(A)$: 어떤 사건 A가 일어날 확률.

- 조건부 확률

$$P(A | B) = \frac{P(A \cap B)}{P(B)}$$

조건부 확률



- 사건이 발생한 횟수 : 12
- A 사건이 발생한 횟수 : $7 + 3 = 10$
- B 사건이 발생한 횟수 : $3 + 2 = 5$
- A 사건과 B 사건이 동시에 일어난 횟수 : 3

1. A 사건이 일어난 확률
- $P(A) = 10 / 12$
2. B 사건이 일어난 확률
- $P(B) = 5 / 12$
3. B 사건이 일어났을 때 A 사건이 일어날 확률
- $P(A|B) = 3 / (3 + 2) = 0.6$
4. A 사건이 일어났을 때 B 사건이 일어날 확률
- $P(B|A) = 3 / (7 + 3) = 0.3$
5. B 사건이 일어났을 때 A 사건이 일어날 확률을 다른 방식으로 계산하는 방법
- $P(A|B) = P(B|A) * P(A) / P(B) = 0.3 * (10/12) / (5/12) = 0.6$

나이브 베이즈 알고리즘을 머신러닝에 응용하기

- A를 타겟, B를 데이터의 특징으로 대입해 보면
 - $P(\text{타겟} | \text{데이터 특징}) = P(\text{데이터 특징} | \text{타겟}) * P(\text{타겟}) / P(\text{데이터 특징})$
- 즉, 어떤 데이터가 있을 때 그에 해당하는 타겟은 기존 데이터의 특징 및 타겟의 확률을 사용해 구할 수 있다는 것.

나이브 베이즈 알고리즘의 기초 응용 사례

- 치킨 집에서 손님이 주문을 할 때 맥주를 주문할지 안 할지 예측.
- 저녁에 손님이 한 명 와서 주문 시 나이브 베이즈 공식에 따르면 손님이 맥주를 주문할 확률.
 - $P(\text{주문}|\text{저녁}) = P(\text{저녁}|\text{주문}) * P(\text{주문}) / P(\text{저녁})$
 $= (3 / 4) * (4 / 10) / (5 / 10) = 0.6$

시간	맥주
오전	주문 안 함
오전	주문 안 함
점심	주문함
점심	주문 안 함
점심	주문 안 함
저녁	주문함
저녁	주문함
저녁	주문함
저녁	주문 안 함
저녁	주문 안 함

- 기존 손님들의 주문 내역

나이브 베이지 알고리즘의 고급 응용 사례

- 치킨 집에 저녁 성인 손님이 주문을 할 때 맥주를 주문할지 안 할지 예측.
- 저녁에 성인 손님이 한 명 와서 주문 시 나이브 베이지 공식에 따르면 손님이 맥주를 주문할 확률.
 - $P(\text{주문}|\text{저녁, 성인})$
 $= P(\text{저녁, 성인}|\text{주문}) * P(\text{주문}) / P(\text{저녁, 성인})$
- 결합 확률 : 두 가지 이상의 사건이 동시에 발생하는 확률.
 - $P(A, B) = P(A|B) P(B)$
 - ✓ 베이지 알고리즘으로 위의 공식을 풀려고 하면 조건부 확률에 따른 많은 계산이 필요하기 때문에 나이브 베이지 알고리즘에서는 나이브(단순)하게 모든 사건을 독립적인 사건으로 간주해 계산의 복잡성을 낮춘다.

시간	성인여부	맥주
오전	성인	주문 안 함
오전	미성년자	주문 안 함
점심	성인	주문함
점심	미성년자	주문 안 함
점심	미성년자	주문 안 함
저녁	성인	주문함
저녁	성인	주문함
저녁	성인	주문함
저녁	성인	주문 안 함
저녁	미성년자	주문 안 함

- 기존 손님들의 주문 내역

독립 사건일 경우의 조건부 확률

- 독립 사건일 경우의 조건부 확률은 다음과 같이 단순해 짐.
 - $P(A, B) = P(A) * P(B)$
- 나이브 베이즈 알고리즘을 통해 “저녁에 성인이 치킨 집에 와서 맥주를 주문할 확률” 계산
 - $P(\text{주문} | \text{저녁}, \text{성인}) = P(\text{저녁} | \text{주문}) * P(\text{성인} | \text{주문}) * P(\text{주문}) / P(\text{저녁}) * P(\text{성인})$
- 나이브 베이즈 알고리즘을 통해 “저녁에 성인이 치킨 집에 와서 맥주를 주문하지 않을 확률” 계산
 - $P(\text{주문 안함} | \text{저녁}, \text{성인})$
 $= P(\text{저녁} | \text{주문 안함}) * P(\text{성인} | \text{주문 안함}) * P(\text{주문 안함}) / P(\text{저녁}) * P(\text{성인})$
- 여기서 실제로 필요한 것은 두 값의 대소를 비교해서 큰 값을 선택하는 것이므로 다음과 같이 공통 분모를 계산식에서 제거해서 계산량을 더 줄일 수 있음.
 - $P(\text{주문} | \text{저녁}, \text{성인}) = P(\text{저녁} | \text{주문}) * P(\text{성인} | \text{주문}) * P(\text{주문}) = 0.3$
 - $P(\text{주문 안함} | \text{저녁}, \text{성인}) = P(\text{저녁} | \text{주문 안함}) * P(\text{성인} | \text{주문 안함}) * P(\text{주문 안함}) = 0.067$

✓ $P(\text{주문} | \text{저녁}, \text{성인})$ 이 더 크므로 저녁에 성인이 치킨 집에 올 경우 맥주를 주문할 것으로 분류.

특징이 여러 개인 경우의 나이브 베이즈 공식

$$P(y | x_1, \dots, x_n) = \frac{P(x_1 | y) P(x_2 | y) \dots P(x_n | y) P(y)}{P(x_1)P(x_2) \dots P(x_n)}$$

- 나이브 가정에 의해 모든 특징들을 독립적인 확률로 계산하는 것을 확인할 수 있음.
- 여러 확률의 곱을 나타내는 $P(x_1 | y) * P(x_2 | y) * \dots * P(x_n | y)$ 부분을 간단하게 공식화하면

$$P(y | x_1, \dots, x_n) = \frac{P(y) \prod_{i=1}^n P(x_i | y)}{P(x_1)P(x_2) \dots P(x_n)}$$

- 모든 레이블들은 모든 특징들의 곱이라는 공통 분모를 가지고 있음.
- 레이블 확률의 대소 비교만 필요한 나이브 베이즈에서는 공통 분모를 제거해서 계산량을 줄일 수 있음.

$$P(y | x_1, \dots, x_n) \propto P(y) \prod_{i=1}^n P(x_i | y)$$

- 공통 분모를 제거한 후, 가장 높은 수치를 지닌 레이블로 데이터를 분류.

$$y = \operatorname{argmax}_y P(y) \prod_{i=1}^n P(x_i | y)$$

가우시안 나이브 베이지 분류

- 데이터의 특징들이 연속적인 경우에는 가우시안 나이브 베이지 분류를 사용하는 것을 추천.
- 특징들의 값들이 정규 분포(가우시안 분포) 특성을 가진다는 가정하에 조건부 확률을 계산.
- 연속적인 성질이 있는 특징이 있는 데이터를 분류하는데 적합.
- 예) 붓꽃(iris) 데이터셋 분류
- cf) 스무딩(smoothing) 이란?
 - 이산적인 데이터의 경우 빈도수가 0인 경우가 발생
 - 예를 들어, 나이브 베이지 기반 스팸 메일 필터를 가동시키는데, 학습 데이터에 없던 단어가 실제 상황에서 나타나게 되면 확률이 0이 되어 스팸 분류가 어려워짐.
 - 스무딩은 학습 데이터에 없던 데이터가 출현해도 빈도수에 1을 더해서 확률이 0이 되는 현상을 방지

사이킷런의 두 가지 나이브 베이즈 분류 모델

● 다항 분포 나이브 베이즈(Multinomial Naïve Bayes) 분류

- 데이터의 특징이 출현 횟수로 표현 됐을 때 사용.
- 예를 들어, 주사위를 10번 던졌을 때 1이 한 번, 2가 두 번, 3이 세 번, 4가 네 번 나왔을 경우, 주사위를 10번 던진 결과 데이터를 (1, 2, 3, 4, 0, 0)과 같이 나타낼 수 있다. 각 인덱스는 주사위의 면을 뜻하며, 데이터의 숫자는 출현 횟수를 나타낸 것임.
- 이와 같이 데이터의 출현 횟수에 따라 값을 달리한 데이터에 사용.
- 예) 영화 감상평을 토대로 긍정적/부정적 리뷰 분류.

● 베르누이 나이브 베이즈 모델(Bernoulli Naïve Bayes)

- 데이터의 특징이 0 또는 1로 표현 됐을 때 사용.
- 예를 들어, 주사위를 10번 던졌을 때 1이 한 번, 2가 두 번, 3이 세 번, 4가 네 번 나왔을 경우, 주사위를 10번 던진 결과 데이터를 (1, 1, 1, 1, 0, 0)과 같이 나타낼 수 있다. 각 인덱스는 주사위의 면을 뜻하며, 숫자가 출현했을 때는 1, 출현하지 않았을 때는 0으로 나타낸 것임.
- 이와 같이 데이터 출현 여부에 따라 1 또는 0으로 구분 됐을 때 사용.
- 예) 스팸 메일 분류

나이브 베이즈 - 장/단점

● 장점

- 모든 데이터의 특징이 독립적인 사건이라는 나이브 가정에도 불구하고 실전에서 높은 정확도를 보이며, 특히 문서 분류 및 스팸 메일 분류에 강한 면모를 보임.
- 나이브 가정에 의해 계산 속도가 다른 모델들에 비해 상당히 빠름.

● 단점

- 모든 데이터의 특징을 독립적인 사건이라고 가정하는 것은 문서 분류에 적합할 지는 모르나, 다른 분류 모델에는 제약이 될 수 있음.