

앙상블 (Ensemble)

앙상블(Ensemble) - 배깅(bagging)

- 여러 개의 분류 모델을 조합해서 더 나은 성능을 내는 방법.
- 배깅(bagging)
 - 한 가지 분류 모델을 여러 개 만들어서 서로 다른 학습 데이터로 학습시킨 후(부트스트랩), 동일한 테스트 데이터에 대한 서로 다른 예측값들을 투표를 통해(aggregating) 가장 높은 예측값으로 최종 결론을 내리는 앙상블 기법.
 - 어원 : 부트스트랩(bootstrap) + 어그리게이팅(aggregating)
 - 과대적합이 되기 쉬운 모델에 상당히 적합한 앙상블.

부트스트랩(Bootstrap)

- 데이터를 조금은 편향되도록 샘플링하는 기법.
- 과대적합 모델의 특징이 학습 데이터에 대한 분산은 높고 편향은 적은 모델.
- 데이터 샘플링 시 편향을 높임으로써 분산이 높은 모델의 과대적합 위험을 줄이는 효과를 줌.
- N개의 데이터를 총 K개의 데이터로 나누어 담는다. 나누어 담을 때 중복을 허용해서 데이터의 편향을 높임.
- 편향된 데이터로 학습된 K개의 의사결정 트리는 N개의 데이터로 학습된 1개의 의사결정 트리보다 편향이 높아 과대적합될 확률이 적어짐.

예) - 전체 데이터 : [1, 2, 3, 4, 5, 6, 7, 8, 9]

- 의사결정 트리 6개를 배깅할 경우

- 의사결정 트리1의 학습 데이터 : [1, 2, 3, 4, 5, 1]
- 의사결정 트리2의 학습 데이터 : [2, 3, 4, 5, 6, 2]
- 의사결정 트리3의 학습 데이터 : [3, 4, 5, 6, 7, 3]
- 의사결정 트리4의 학습 데이터 : [4, 5, 6, 7, 8, 4]
- 의사결정 트리5의 학습 데이터 : [5, 6, 7, 8, 9, 5]
- 의사결정 트리6의 학습 데이터 : [6, 7, 8, 9, 1, 6]

- 각 분류 모델은 총 N개의 데이터보다 적은 데이터로 학습.
- 중복된 데이터를 허용함으로써 편향이 높은 학습 데이터로 학습.
- 데이터 샘플링 크기는 보통 전체 데이터의 60~70%를 사용.

Aggregating

- 여러 분류 모델이 예측한 값들을 조합해서 하나의 결론을 도출하는 과정.
- 결론은 투표를 통해 결정.
- 하드 보팅(Hard Voting)
 - 배깅에 포함된 K개의 분류 모델에서 최대 득표를 받은 예측값으로 결론을 도출.
 - ex) 손글씨 숫자를 보고, 숫자를 1~9로 분류하는 의사결정 트리 6개를 학습한 후, 숫자 7을 보여줬을 경우 다음과 같이 각각 분류했다고 가정.

분류모델	분류값
의사결정 트리1	1
의사결정 트리2	2
의사결정 트리3	7
의사결정 트리4	7
의사결정 트리5	7
의사결정 트리6	7

- 총 6개의 투표 중, 7이 4개의 최다 득표를 받아 하드보팅 어 그리게이팅은 7로 입력값을 정확히 예측.

Aggregating

- 소프트 보팅(Soft Voting)

- 하드 보팅보다 더 정교한 투표 방식.
- 하드 보팅 같은 경우 각 분류 모델은 최고의 확률을 갖는 분류값만을 aggregating할 때 리턴하는 반면, 소프트 보팅은 모든 분류값의 확률을 리턴함.
- 따라서 하드 보팅은 단순히 가장 많은 투표를 받은 분류값을 단순히 aggregating의 결론으로 도출하는 반면, 소프트 보팅은 각 분류값별 확률을 더해준 값을 점수로 사용해 최대 점수를 가진 분류값을 결론으로 도출함.
- ex)

분류모델	1	2	3	4	5	6	7	8	9
의사결정 트리1	0.9	0.1	0	0	0	0	0	0	0
의사결정 트리2	0	0.8	0.1	0.1	0	0	0	0	0
의사결정 트리3	0	0	0.1	0	0	0	0.9	0	0
의사결정 트리4	0	0	0	0.1	0	0	0.9	0	0
의사결정 트리5	0	0	0	0	0	0	1	0	0
의사결정 트리6	0.4	0	0	0	0	0	0.6	0	0

- 숫자 7이 입력됐을 때 각 의사결정 트리의 분류값별 확률

분류값	확률값	최종점수
1	0.9+0.4	1.3
2	0.1+0.8	0.9
3	0.1+0.1	0.2
4	0.1+0.1	0.2
5	0	0
6	0	0
7	0.9+0.9+1+0.6	3.4
8	0	0
9	0	0

- 소프트 보팅의 각 분류값별 점수 계산

랜덤 포레스트(RandomForest)

- 여러 의사결정 트리를 배깅해서 예측을 실행하는 모델.
- 배깅이 모든 분류 모델에 적용 가능하지만, 특히 과대적합되기 쉬운 의사결정 트리에 적용하면 확실히 과대적합을 줄여 성능이 높아지는 혜택을 보기 때문에 배깅은 많은 의사결정 트리 모델의 개선을 이뤘고, 여러 개의 나무들이 모여 있다는 개념에서 랜덤 프레스트라는 이름이 생겨남.
- 의사결정 트리에서는 최적의 특징으로 트리를 분기하는 반면, 랜덤 포레스트는 각 노드에 주어진 데이터를 샘플링해서 일부 데이터를 제외한 채 최적의 특징을 찾아 트리를 분기함.
- 이러한 과정에서 랜덤 포레스트는 또 한 번의 모델의 편향을 증가시켜 과대적합의 위험을 감소시킴.

랜덤 포레스트(RandomForest)

- 장점

- 앙상블 효과로 의사결정 트리의 과대적합 단점을 보완한다.

- 단점

- 조정해야 할 하이퍼 파라미터가 많다.

앙상블(Ensemble) - 부스팅(Boosting)

- 여러 개의 약한 Decision Tree를 조합해서 사용하는 Ensemble 기법 중 하나.
 - 즉, 약한 예측 모형들의 학습 에러에 가중치를 두고, 순차적으로 다음 학습 모델에 반영하여 강한 예측 모형을 만드는 것.
- 여러 개의 분류기를 만들어 투표를 통해 예측값을 결정한다는 측면에서 배깅과 동일.
- 배깅은 서로 다른 알고리즘에 기반한 여러 분류기를 병렬적으로 학습하는 반면, 부스팅은 동일한 알고리즘의 분류기를 순차적으로 학습해서 여러 개의 분류기를 만든 후, 테스트할 때 가중 투표를 통해 예측값을 결정.
- 순차적 학습과 가중 투표가 부스팅의 가장 큰 특징.

부스팅 - 순차적 학습

- 인물 사진 안에 있는 인물을 보고, 남자 또는 여자로 분류하는 의사결정 트리를 부스팅할 경우, 먼저 첫 번째 의사결정 트리를 학습함.
- 테스트 결과, 남자 분류가 미흡할 경우, 남자 학습 데이터를 보강한 후 두 번째 의사결정 트리를 학습함.
- 그리고 두 번째 의사결정 트리의 테스트 결과에 따라 학습 데이터를 보강해서 세 번째 의사결정 트리를 학습함.
- 이처럼 부스팅은 순차적으로 학습 데이터를 보강하며 동일한 알고리즘의 분류기를 여러 개 만드는 과정을 가짐.

부스팅 - 가중 투표

- 배깅은 마치 우리가 선거를 하듯, 동일한 한 표씩 부여되는 반면 부스팅은 가중 투표가 진행됨.
- 가중 투표는 투표자의 능력치에 따라 한 표의 가치가 다른 투표임.
- 팀회식 장소를 결정하는데, 사원 5명이 클럽에 가자고 했지만 부장님 3명이 삼겹살을 먹으러 가자고 했을 때, 삼겹살로 회식이 결정되는 것과 같음.
- 3가지 분류기의 검증 결과, 정확도가 다음과 같다고 가정하면

	분류기1	분류기2	분류기3
정확도	0.4	0.5	0.95

- 세 분류기의 정확도

	분류기1	분류기2	분류기3
분류값	남자	남자	여자

- 세 분류기의 분류값(하드보팅)

- 이 경우 가중 투표는 다음과 같이 진행.

- 하드 보팅

✓ 남자 : $0.4 + 0.5$, 여자 : 0.95

✓ 따라서 두 분류기가 남자라고 예측했음에도 가중 투표 결과, 사진의 인물을 여자로 분류.

- 소프트 보팅

✓ 남자: $0.4 \times 0.7 + 0.5 \times 0.8 + 0.95 \times 0.1 = 0.775$

✓ 여자: $0.4 \times 0.3 + 0.5 \times 0.2 + 0.95 \times 0.9 = 1.075$.

✓ 소프트 보팅의 결과, 여자로 최종 결론 도출.

	분류기1	분류기2	분류기3
분류값	남자: 0.7 여자: 0.3	남자: 0.8 여자: 0.2	남자: 0.1 여자: 0.9

- 세 분류기의 분류값(소프트보팅)