

군집화

(Clustering)

군집화(Clustering)

- 비지도학습의 일종으로, 데이터의 특징만으로 비슷한 데이터들끼리 모아 군집된 클래스로 분류함
- K 평균 알고리즘 - 간단하면서도 강력한 군집화 알고리즘
- K 평균 알고리즘의 진행 순서
 1. 데이터 준비
 2. 몇 개의 클래스로 분류할 것인지 설정
 3. 클러스터의 최초 중심 설정
 4. 데이터를 가장 가까운 클러스터로 지정
 5. 클러스터 중심을 클러스터에 속한 데이터들의 가운데 위치로 변경
 6. 클러스터 중심이 바뀌지 않을 때까지 4번부터 5번 과정을 반복적으로 수행

k 평균 알고리즘 - (1) 데이터 준비

- k 평균 알고리즘은 데이터 간의 거리를 사용해 가까운 거리에 있는 데이터끼리 하나의 클래스로 묶는 알고리즘.
- 거리를 계산하기 위해 데이터는 수치화된 데이터여야 함.
- 이해를 돕기 위해 한 교실에 있는 학생들의 키와 몸무게 값으로 세 개의 군집으로 분류하는 예제를 살펴봄.

학생	키	몸무게
1	185	60
2	180	60
3	185	70
4	165	63
5	155	68
6	170	75
7	175	80

k 평균 알고리즘

- (2) 몇 개의 클래스로 분류할 것인지 정하기



- k 평균 알고리즘의 k는 몇 개의 클래스로 분류할 것인지를 나타내는 변수
- 이번 예제에서는 k를 3으로 설정해 학생들을 세 개의 집단으로 분류

- (3) 클러스터의 최초 중심 설정

- k 평균의 표준 알고리즘은 클러스터의 최초 중심을 무작위로 설정함
- 경우에 따라 최초 중심을 k 평균 모델에 부여할 수도 있음
 - 예를 들어, 서울의 각 지역구별 위도/경도 데이터만 있을 때 강동, 강서, 강남, 강북으로 군집화하기 위해 가장 좋은 방법은 강동, 강서, 강남, 강북의 정가운데에 있는 지역구를 최초 클러스터의 중심으로 부여하는 것일 것
- 사이킷런의 k 평균 라이브러리
 - 기본적으로 kmean++라는 알고리즘을 써서 클러스터의 최초 중심을 설정함
 - kmean++는 최초 데이터 포인트 지점을 첫 번째 클러스터의 중심으로 설정하고, 최초 데이터 포인트에서 가장 먼 데이터 포인트를 두 번째 클러스터의 중심으로, 그리고 기존의 클러스터 중심에서 가장 먼 데이터 포인트를 그 다음 클러스터의 중심으로 설정
 - 표준 k 평균 알고리즘의 랜덤 중심 설정은 때로는 초기 중심이 한 군데로 집약되어 군집하는 데 시간이 오래 걸리고, 군집의 결과가 나쁠 경우가 더러 있어 단점을 보완하고자 만들어진 알고리즘



k 평균 알고리즘

- 클러스터의 최초 중심 설정 - 무작위로 클러스터 중심 정하기.





k 평균 알고리즘

- 클러스터의 최초 중심 설정 - kmean++의 중심 정하기.





k 평균 알고리즘

- 표준 k 평균 알고리즘에 따라 무작위로 클러스터의 중심을 설정하고 각 (4) 데이터를 가장 가까운 클러스터에 지정하는 과정.





k 평균 알고리즘

- 표준 k 평균 알고리즘에 따라 무작위로 클러스터의 중심을 설정하고 각 (4) 데이터를 가장 가까운 클러스터에 지정하는 과정.





k 평균 알고리즘

- 표준 k 평균 알고리즘에 따라 무작위로 클러스터의 중심을 설정하고 각 (4) 데이터를 가장 가까운 클러스터에 지정하는 과정.





k 평균 알고리즘

- 표준 k 평균 알고리즘에 따라 무작위로 클러스터의 중심을 설정하고 각 (4) 데이터를 가장 가까운 클러스터에 지정하는 과정.



k 평균 알고리즘

- 데이터 순회가 완료되면 각 (5) 클러스터 중심을 클러스터에 속한 데이터들의 가운데 위치로 변경.



K 평균 알고리즘

- 클러스터의 중심이 바뀌면 다시 첫 번째 데이터부터 마지막 데이터까지 순회하며, 데이터를 가장 가까운 클러스터로 소속 시키며, (6) 클러스터 중심이 바뀌지 않을 때까지 (4)번부터 (5)번 과정을 반복 수행.

