

주성분 분석


(Principal Component Analysis,
PCA)

주성분 분석(Principal Component Analysis, PCA)


- 고차원의 데이터를 저차원의 데이터로 차원 축소하는 알고리즘.
- 주로 고차원의 데이터를 3차원 이하의 데이터로 바꿔서 시각화하는 데 많이 사용.
- 유용한 정보만 살려서 적은 메모리에 저장하거나 데이터의 노이즈를 줄이고 싶을 때도 사용.
- 주성분 분석의 특징
 - 데이터의 분산을 최대한 유지하면서 저차원으로 데이터를 변환하는데 있음.
 - 분산을 유지하는 이유는 데이터의 고유한 특성을 최대한 유지하기 위함.

주성분 분석(Principal Component Analysis, PCA)

- 이해를 위해 쉽게 시각화 가능한 2차원 데이터를 1차원 데이터로 축소하는 과정을 살펴봄.
- 단순히 2차원 데이터를 x_1 축으로 옮긴다면 다음과 같을 것.




- 2차원 데이터포인트 분포도




- 2차원 데이터를 x_1 축에 투영시켰을 때의 시각화

주성분 분석(Principal Component Analysis, PCA)

- 단순히 2차원 데이터를 x_2 축으로 옮긴다면 다음과 같을 것.



- 2차원 데이터포인트 분포도




- 2차원 데이터를 x_2 축에 투영시켰을 때의 시각화


- 2차원 데이터를 1차원으로 옮겼다는 점에서는 성공적임.
- 2차원 상에 있었을 때 확실하게 구분됐던 7개의 점이, 1차원 직선상에서 많이 중첩되어 데이터를 구분하기가 어려워진 것을 눈으로 확인할 수 있음.

주성분 분석(Principal Component Analysis, PCA)

- 7개의 점들이 확실하게 구분된 1차원 직선.



- 2차원 데이터포인트 분포도




- 투영 시 정보의 유실이 없는 1차원 직선


- 1차원 상에 점들이 있음에도 데이터가 하나도 중복되지 않고 육안으로 7개의 점을 확인할 수 있음.
- 정보 이론 측면에서 해석해 본다면 고차원 데이터를 저차원 데이터로 옮겼음에도 유용한 정보의 유실이 가장 적다고 판단할 수 있음.

주성분 분석(Principal Component Analysis, PCA)

- 주성분 분석 알고리즘은 수학적 방법으로 데이터 정보의 유실이 가장 적은 라인을 찾아냄.
- 수학적으로 '데이터의 중첩이 가장 적다' 라는 말은 '데이터의 분산이 가장 크다' 라는 말과 동일.
- 주성분 분석은 아래 그림과 같이 분산이 가장 큰 차원을 선택해 고차원 데이터를 저차원으로 축소함.
- 분산이 가장 큰 차원은 수학적으로 공분산 행렬(covariance matrix)에서 고유값(eigen value)이 가장 큰 고유 벡터(eigen vector)임.



- 각 직선별 분산 비교



- 고유 벡터 시각화

- 데이터가 5차원 데이터이고, 2차원으로 데이터의 차원을 줄이고 싶다면 주성분 분석 알고리즘은 공분산 행렬에서 고유값이 큰 순서대로 고유벡터를 정렬한 후, 가장 큰 고유 벡터와 두 번째로 큰 고유 벡터를 축으로 2차원 데이터를 만들게 됨.